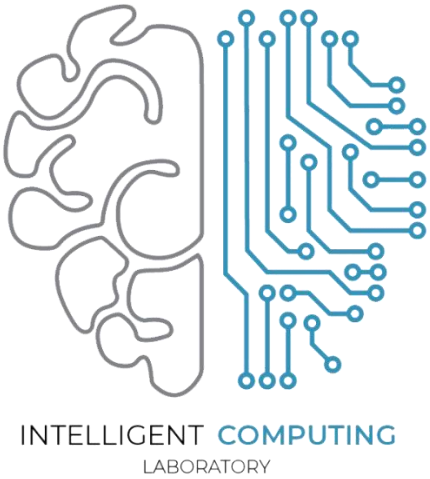
LAPORAN PRAKTIKUM

PEMBELAJARAN MESIN



NAMA : Siti Shafira Shafarina.A

NIM : 202431077

KELAS : C

DOSEN : Dr. Efy Yosrita, S.Si., M.Kom

NO.PC : 14

ASISTEN : 1. Muhammad Raka Ilham

2. Sharira Maharani

3. Muhammad Jabbar

4. Muhammad Fachrydzi Irfansyah

INSTITUT TEKNOLOGI PLN

TEKNIK INFORMATIKA

2025/2026

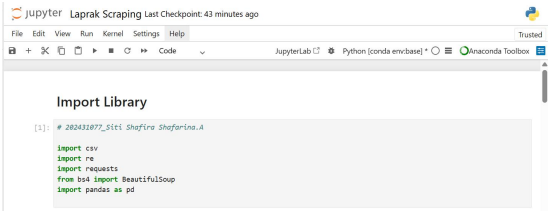
1. EDA:

Makna Dataset: Dataset ini berisi data nilai ujian siswa berdasarkan beberapa karakteristik, seperti jenis kelamin, kelompok etnis, tingkat pendidikan orang tua, jenis makan siang, dan keikutsertaan dalam persiapan ujian. Dataset juga mencakup nilai matematika, membaca, dan menulis.

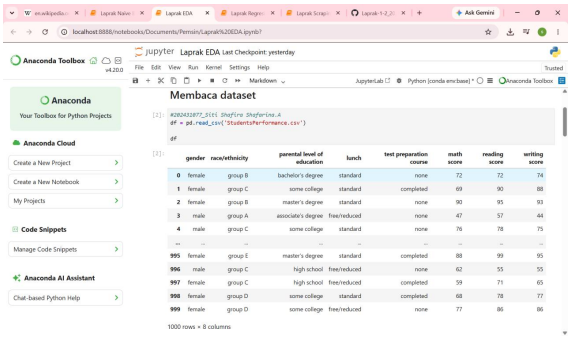
Dataset ini digunakan untuk menganalisis hasil belajar siswa serta melihat hubungan antara karakteristik siswa dan nilai ujian yang diperoleh.

Students Performance in Exams, https://www.kaggle.com/datasets/spscientist/students-performance-in-exams, 1.000 baris × 8 kolom.

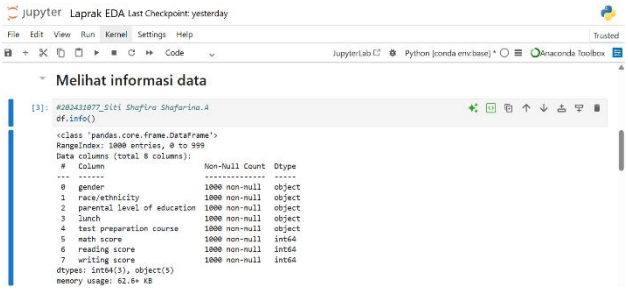
Program:



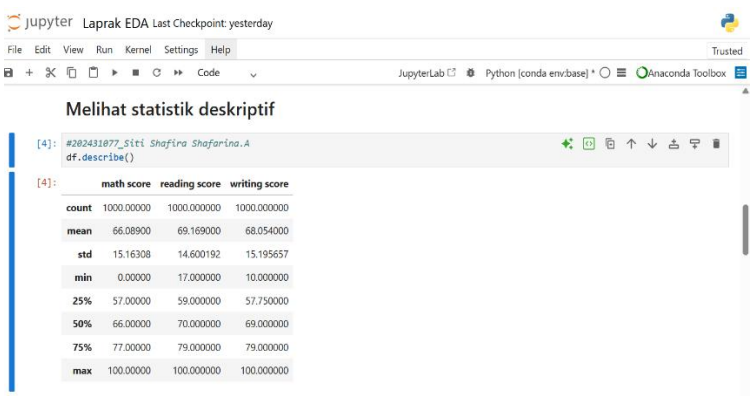
Kode ini mengimpor beberapa library Python, yaitu Pandas untuk mengolah data, NumPy untuk operasi numerik, Matplotlib dan Seaborn untuk membuat visualisasi data. Library tersebut digunakan dalam proses Exploratory Data Analysis (EDA).



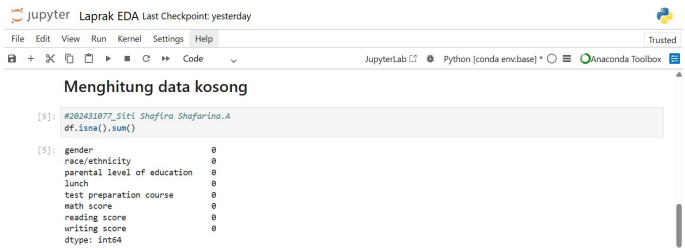
Kode ini digunakan untuk membaca dataset menggunakan Pandas. Data tersebut berisi informasi karakteristik siswa dan nilai ujian matematika, membaca, serta menulis yang akan dianalisis pada tahap EDA.



Kode ini digunakan untuk melihat struktur dataset dan tipe data setiap kolom. Hasilnya menunjukkan bahwa dataset memiliki 8 kolom dengan tipe data kategori dan numerik, serta seluruh data terisi tanpa nilai kosong.



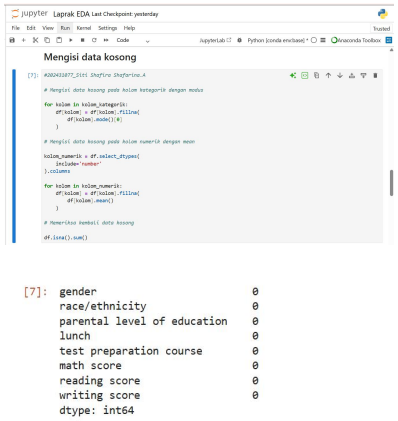
Kode ini digunakan untuk mengetahui gambaran umum nilai ujian matematika, membaca, dan menulis. Hasil statistik membantu melihat sebaran serta rentang nilai siswa dalam dataset.



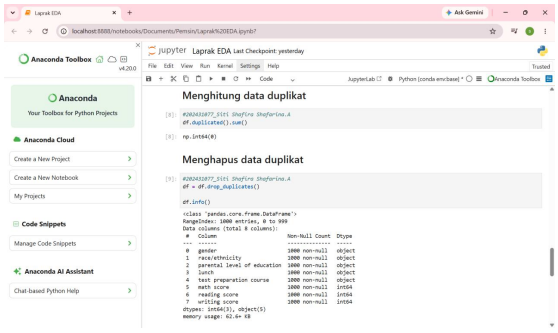
Kode ini digunakan untuk memeriksa apakah terdapat data yang kosong (missing values). Hasilnya menunjukkan tidak ada data kosong sehingga dataset dapat dilanjutkan ke tahap analisis.



Kode ini digunakan untuk mengetahui variasi kategori dalam dataset. Hasilnya membantu memahami pilihan nilai pada setiap kolom sebelum data dianalisis lebih lanjut.

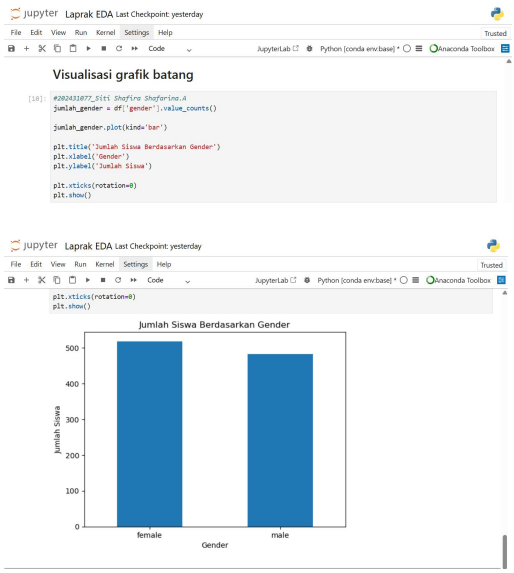


Kode ini menangani data kosong dengan mengisi kolom kategori menggunakan modus dan kolom numerik menggunakan rata-rata. Karena dataset sejak awal tidak memiliki data kosong, hasilnya tetap menunjukkan 0 pada seluruh kolom.



Menghitung data Duplikat: Kode ini digunakan untuk menghitung jumlah baris data yang duplikat. Hasil 0 menunjukkan bahwa tidak terdapat data duplikat dalam dataset.

Menghapus data duplikat: Kode ini digunakan untuk menghapus baris yang memiliki data duplikat. Karena sebelumnya tidak ditemukan data duplikat, jumlah dataset tetap 1.000 baris dan 8 kolom.



Kode ini digunakan untuk memvisualisasikan jumlah siswa berdasarkan gender. Diagram batang memudahkan perbandingan jumlah siswa laki-laki dan perempuan sehingga data lebih mudah dipahami.

2. Scraping

https://en.wikipedia.org/robots.txt

2. Screenshot:



3. Aturan yang terlihat pada bagian User-agent: * antara lain:

- Disallow: /w/
- Disallow: /api/
- Disallow: /trap/
- Disallow: /wiki/Special:

4. Halaman yang digunakan adalah:

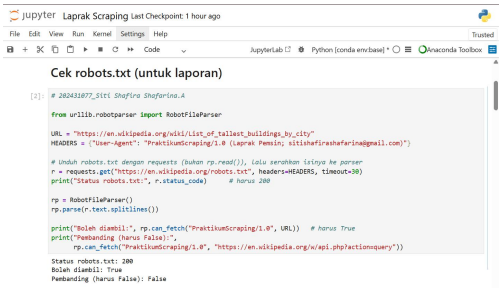
https://en.wikipedia.org/wiki/List_of_tallest_buildings_by_city

Berdasarkan aturan robots.txt untuk User-agent: *, halaman /wiki/List_of_tallest_buildings_by_city tidak termasuk dalam direktori yang dilarang. Oleh karena itu, halaman tersebut tidak diblokir untuk scraping, dengan tetap memperhatikan batasan penggunaan situs Wikipedia.

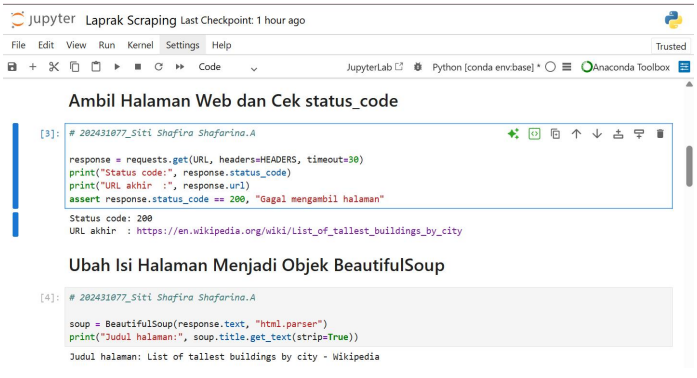
Program:



Kode ini mengimpor beberapa library yang digunakan untuk proses scraping, yaitu Requests untuk mengambil halaman web, BeautifulSoup untuk membaca struktur HTML, CSV untuk menyimpan data, Pandas untuk mengolah data, dan Regex untuk membantu pencocokan teks.

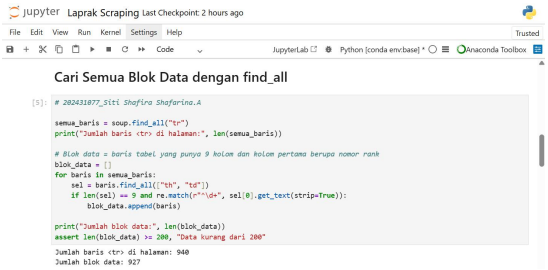


Kode ini digunakan untuk memeriksa aturan robots.txt Wikipedia. Hasilnya menunjukkan file berhasil diakses dengan status 200, halaman tujuan tidak diblokir (True), sedangkan alamat pembanding diblokir (False).

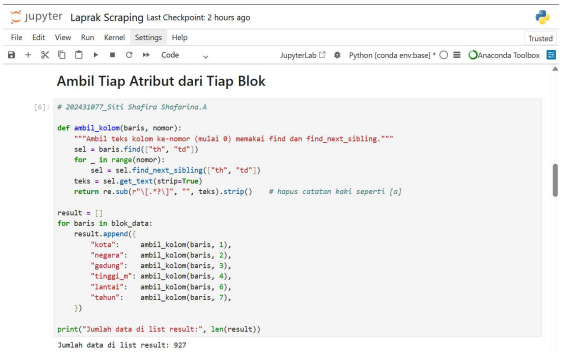


Mengambil Halaman Web dan Memeriksa Status: Kode ini digunakan untuk mengambil halaman Wikipedia menggunakan Requests. Status 200 menunjukkan halaman berhasil diakses dan URL akhir menunjukkan alamat halaman yang berhasil diambil.

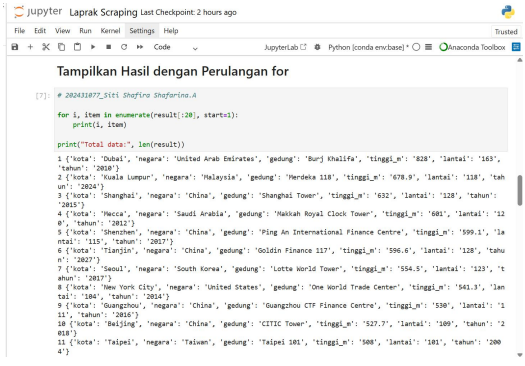
Mengubah Isi Halaman Menjadi Objek BeautifulSoup: Kode ini mengubah isi halaman HTML menjadi objek BeautifulSoup agar struktur halaman dapat dibaca dan diambil datanya. Output menampilkan judul halaman Wikipedia yang berhasil dibaca.



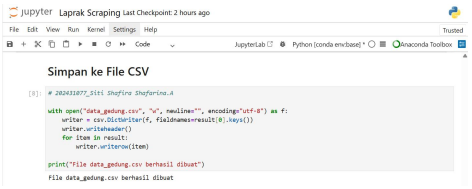
Kode ini menyaring baris tabel yang memiliki 9 kolom dan diawali nomor peringkat. Dari 940 baris yang ditemukan, diperoleh 927 baris data gedung. Jumlah tersebut telah memenuhi syarat minimal 200 data untuk praktikum scraping.



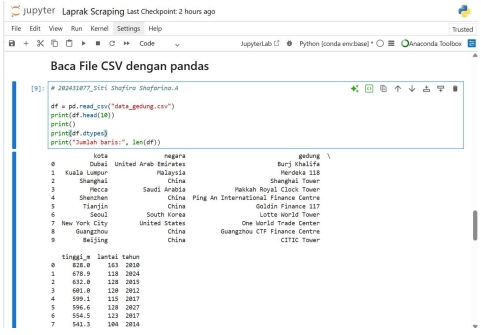
Kode ini mengambil informasi kota, negara, nama gedung, tinggi, jumlah lantai, dan tahun pembangunan dari setiap baris tabel. Catatan kaki pada data juga dihapus agar hasil lebih bersih. Total data yang berhasil dikumpulkan sebanyak 927 baris.

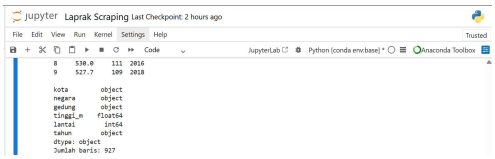


Kode ini digunakan untuk menampilkan 20 data pertama sebagai contoh hasil scraping. Dari seluruh proses pengambilan data, berhasil diperoleh 927 data gedung yang siap diproses ke tahap berikutnya.

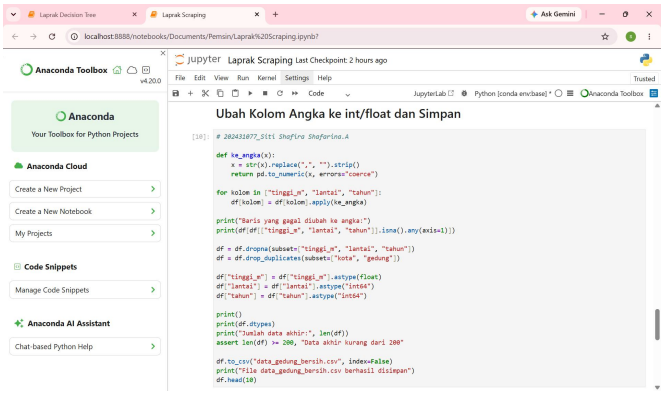


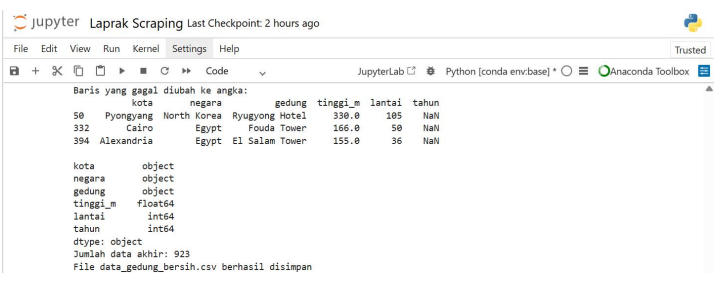
Kode ini digunakan untuk menyimpan 927 data hasil scraping ke dalam file data_gedung.csv. Data disimpan dalam format CSV dengan nama kolom sebagai header sehingga dapat dibaca dan diolah kembali menggunakan Pandas.

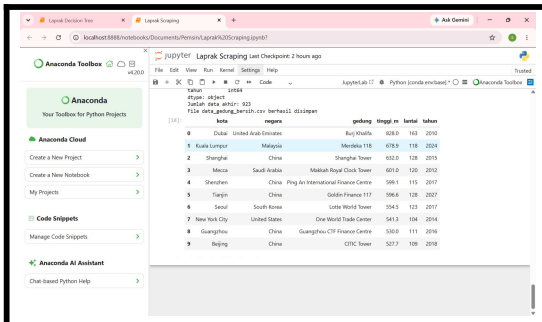




Kode ini digunakan untuk membaca kembali file CSV menggunakan Pandas dan memeriksa hasil penyimpanan data scraping. Pemeriksaan dilakukan untuk melihat isi dataset, tipe data setiap kolom, serta memastikan jumlah data yang berhasil disimpan.

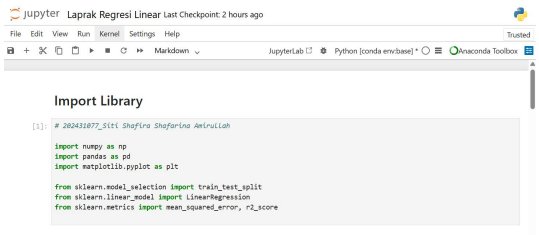




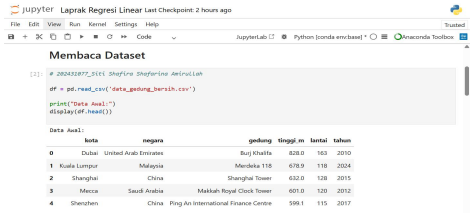


Kode ini digunakan untuk mengubah kolom tinggi, jumlah lantai, dan tahun menjadi tipe numerik. Data kosong dan duplikat dihapus, kemudian dataset bersih disimpan ke file CSV. Hasil akhirnya sebanyak 923 data dan telah memenuhi syarat minimal 200 data.

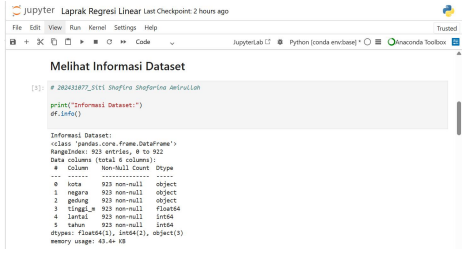
3. Regresi Linear



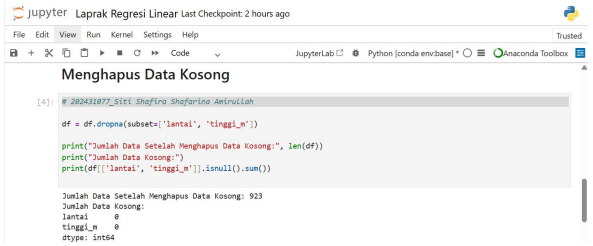
Kode ini mengimpor library untuk mengolah data, membuat visualisasi, membagi dataset, membangun model regresi linear, dan mengevaluasi hasil prediksi.



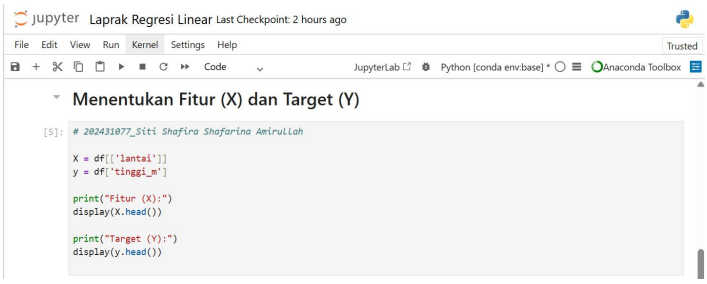
Kode ini digunakan untuk membaca dataset hasil scraping yang telah dibersihkan. Data tersebut akan digunakan untuk memprediksi tinggi gedung berdasarkan jumlah lantainya.

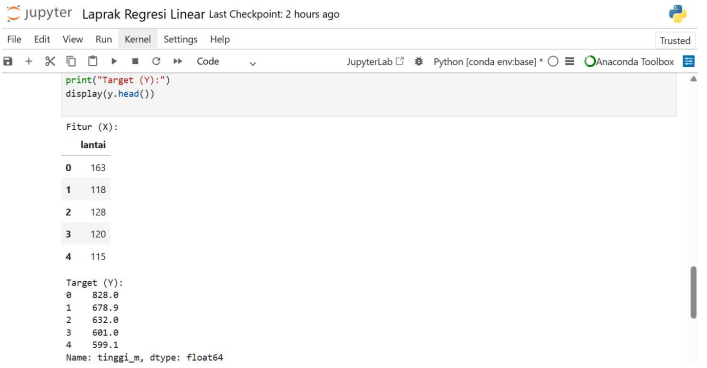


Kode ini digunakan untuk memeriksa struktur dataset dan tipe data setiap kolom. Informasi tersebut membantu memastikan data siap digunakan untuk proses regresi linear.

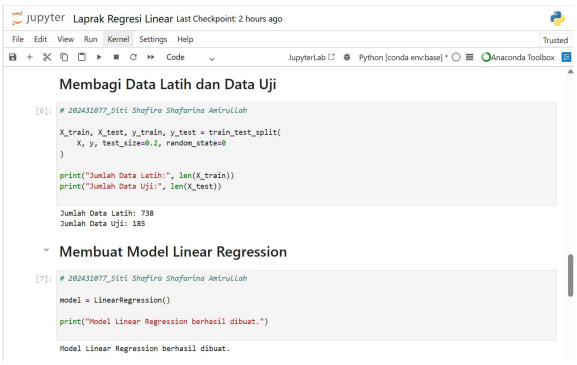


Kode ini digunakan untuk menghapus baris yang memiliki nilai kosong pada kolom jumlah lantai dan tinggi gedung. Hasil pemeriksaan menunjukkan apakah kedua kolom tersebut sudah lengkap untuk digunakan dalam pemodelan regresi linear.



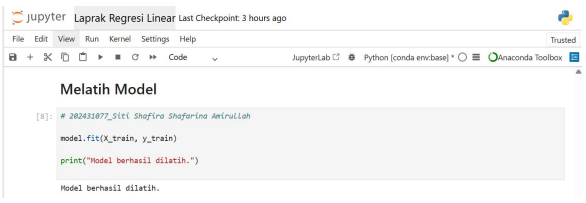


Kode ini menentukan jumlah lantai sebagai variabel bebas (X) dan tinggi gedung sebagai variabel target (Y). Model akan mempelajari hubungan keduanya untuk memprediksi tinggi gedung berdasarkan jumlah lantai.

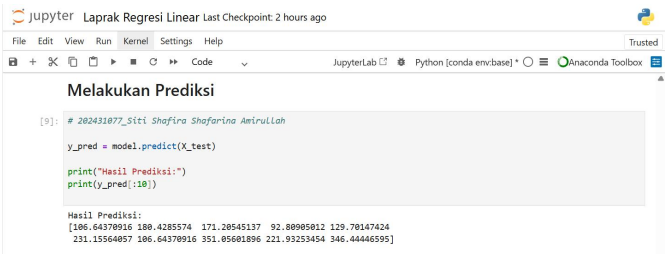


Membagi Data Latih dan Data Uji: Kode ini membagi dataset menjadi 80% data latih dan 20% data uji. Data latih digunakan untuk membangun model, sedangkan data uji digunakan untuk mengukur kemampuan model dalam memprediksi tinggi gedung.

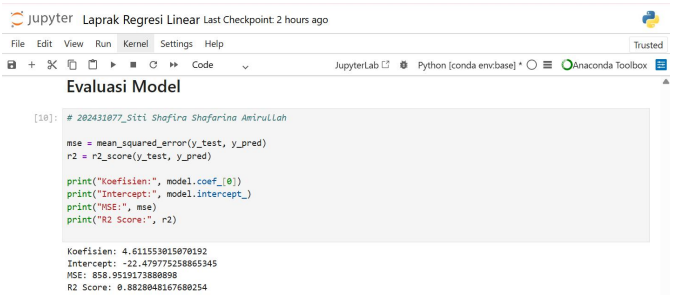
Membuat Model Linear Regression: Kode ini digunakan untuk membuat model Linear Regression yang akan mempelajari hubungan antara jumlah lantai dan tinggi gedung. Model yang berhasil dibuat siap digunakan untuk proses pelatihan.



Kode ini digunakan untuk melatih model menggunakan data latih. Model mempelajari hubungan antara jumlah lantai dan tinggi gedung agar dapat digunakan untuk memprediksi tinggi gedung.



Kode ini digunakan untuk memprediksi tinggi gedung menggunakan model yang telah dilatih. Hasil prediksi berupa perkiraan tinggi gedung berdasarkan jumlah lantainya.

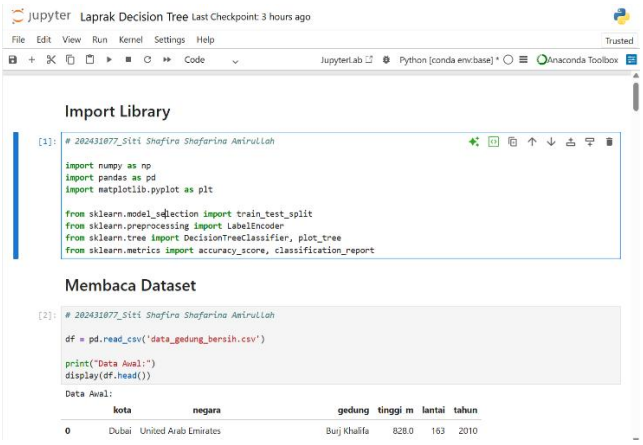


Kode ini digunakan untuk mengukur kinerja model dalam memprediksi tinggi gedung. MSE menunjukkan rata-rata kesalahan prediksi, sedangkan R^2 Score menunjukkan seberapa baik model menjelaskan hubungan antara jumlah lantai dan tinggi gedung.



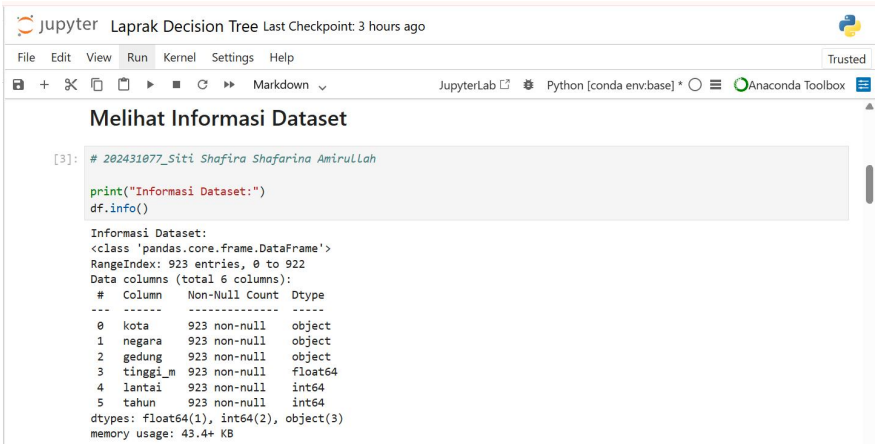
Kode ini digunakan untuk menampilkan persamaan regresi berdasarkan hasil pelatihan model. Persamaan tersebut menunjukkan bahwa setiap penambahan satu lantai diperkirakan meningkatkan tinggi gedung sebesar 4,6116 meter. Nilai -22,4978 merupakan konstanta dalam persamaan regresi.

4.Decision Tree

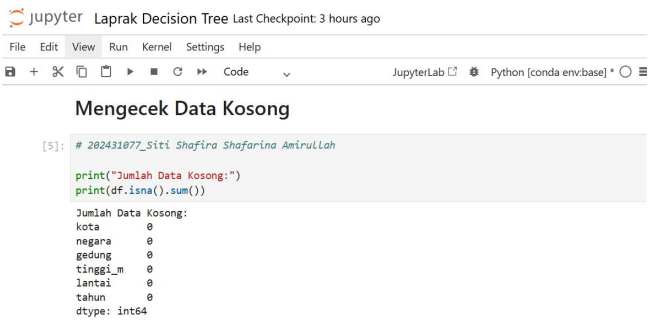


Import Library: Kode ini mengimpor library untuk mengolah data, membuat visualisasi, mengubah data kategori, membangun model Decision Tree, serta mengevaluasi tingkat akurasi dan hasil klasifikasi.

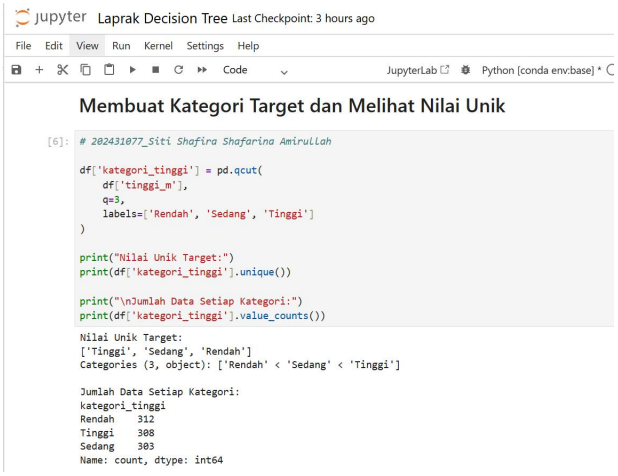
Membaca Dataset: Kode ini digunakan untuk membaca dataset hasil scraping yang telah dibersihkan. Data tersebut digunakan untuk mengelompokkan gedung berdasarkan kategori populasi



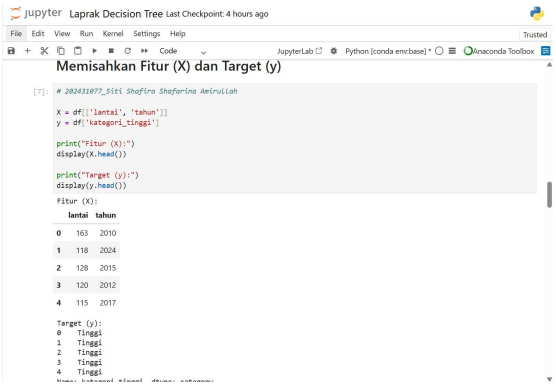
Kode ini digunakan untuk memeriksa struktur dan tipe data dataset. Hasilnya membantu memastikan data telah terbaca dengan baik sebelum dilakukan proses klasifikasi menggunakan Decision Tree.



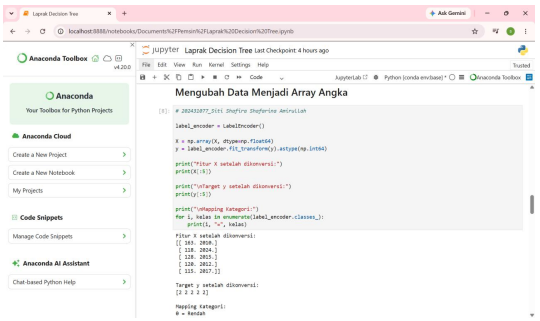
Kode ini digunakan untuk memeriksa nilai kosong (missing values) pada setiap kolom. Hasil pemeriksaan membantu mengetahui apakah dataset memerlukan proses penanganan data kosong sebelum digunakan dalam klasifikasi.



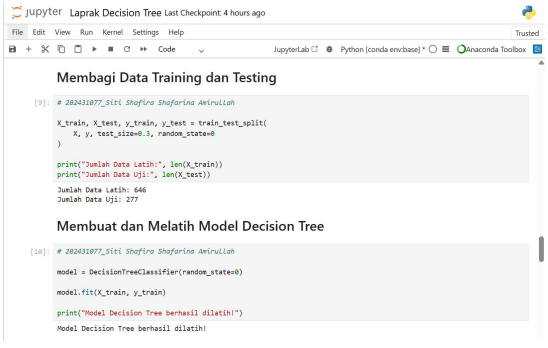
Kode ini mengelompokkan tinggi gedung menjadi tiga kategori berdasarkan pembagian kuantil. Hasilnya digunakan sebagai target klasifikasi agar model Decision Tree dapat memprediksi kategori tinggi gedung.



Kode ini menentukan jumlah lantai dan tahun pembangunan sebagai fitur, sedangkan kategori tinggi gedung menjadi target. Data tersebut digunakan oleh model Decision Tree untuk mempelajari pola pengelompokan tinggi gedung ke dalam kategori Rendah, Sedang, dan Tinggi.

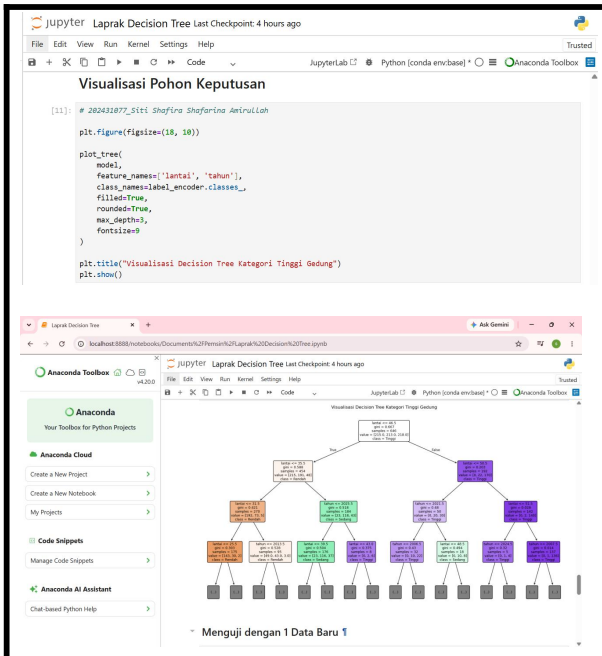


Kode ini mengubah fitur dan target ke format numerik agar dapat diproses oleh model Decision Tree. Label Encoder mengubah kategori target menjadi angka sehingga model dapat melakukan klasifikasi berdasarkan data tersebut.

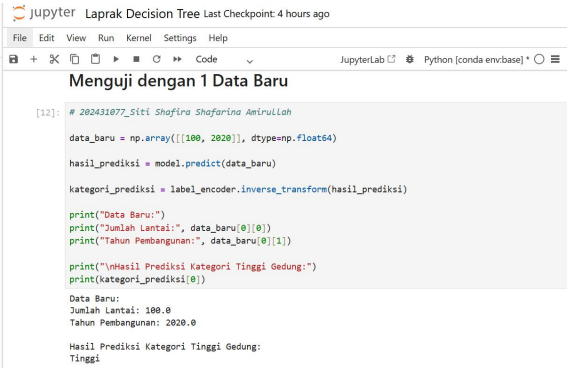


Membagi Data Training dan Testing: Kode ini membagi dataset menjadi 70% data latih dan 30% data uji. Data latih digunakan untuk membangun model, sedangkan data uji digunakan untuk mengukur kemampuan model dalam mengklasifikasikan kategori tinggi gedung.

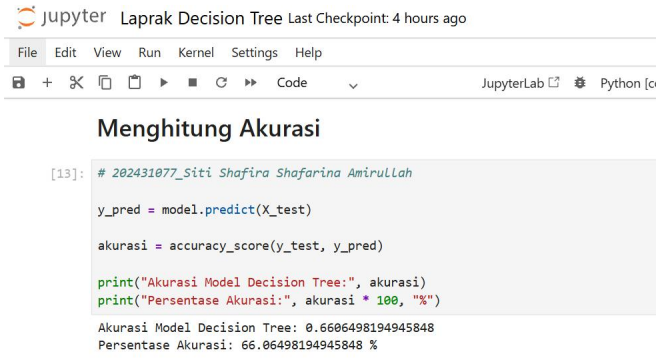
Membuat dan Melatih Model Decision Tree: Kode ini digunakan untuk membuat dan melatih model Decision Tree menggunakan data training. Model mempelajari pola berdasarkan jumlah lantai dan tahun pembangunan untuk mengklasifikasikan gedung ke dalam kategori Rendah, Sedang, atau Tinggi.



Kode ini digunakan untuk menampilkan visualisasi model Decision Tree. Diagram menunjukkan aturan percabangan yang dipelajari model dalam menentukan kategori tinggi gedung, yaitu Rendah, Sedang, dan Tinggi.



Kode ini digunakan untuk menguji model dengan data gedung baru. Model memprediksi kategori tinggi gedung berdasarkan jumlah lantai dan tahun pembangunan yang dimasukkan. Hasil prediksi menunjukkan kategori yang dipilih oleh model.



Kode ini digunakan untuk mengukur tingkat ketepatan model Decision Tree dalam mengklasifikasikan data uji. Semakin tinggi nilai akurasi, semakin banyak prediksi model yang sesuai dengan kategori sebenarnya.

Classification Report

```
[14]: # 202431077_Siti Shafira Shafarina Amirullah

print("Classification Report:")
print(classification_report(
    y_test,
    y_pred,
    target_names=label_encoder.classes_
))
```

```
Classification Report:
              precision    recall  f1-score   support

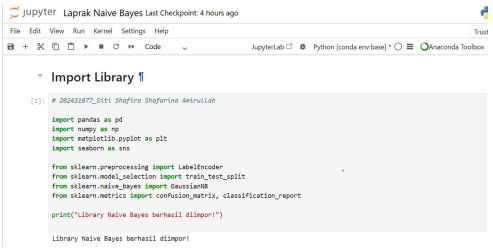
      Rendah       0.65      0.74      0.69        97
      Sedang       0.51      0.50      0.50        90
      Tinggi       0.86      0.73      0.79        90

    accuracy                           0.66       277
   macro avg       0.67      0.66      0.66       277
weighted avg       0.67      0.66      0.66       277
```

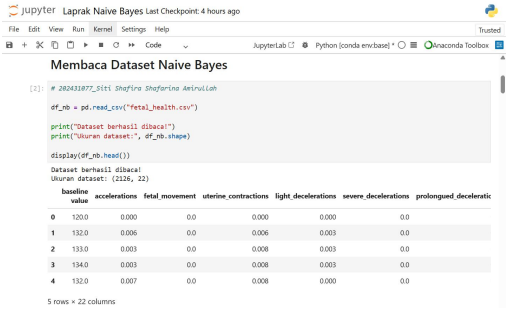
Kode ini digunakan untuk mengevaluasi performa model pada setiap kategori. Hasilnya menunjukkan ketepatan prediksi, kemampuan model mengenali setiap kategori, serta jumlah data uji pada masing-masing kategori.

5.Naive Bayes

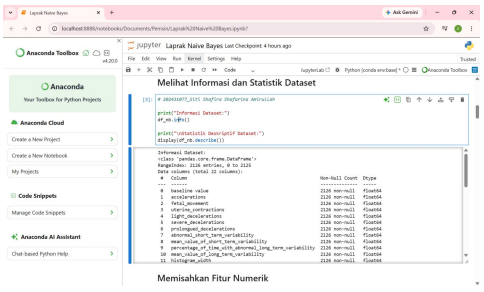
fetal Health Classification, Link Kaggle: https://www.kaggle.com/datasets/andrewmvd/fetal-health-classification, Jumlah Data: 2.126 baris × 22 kolom



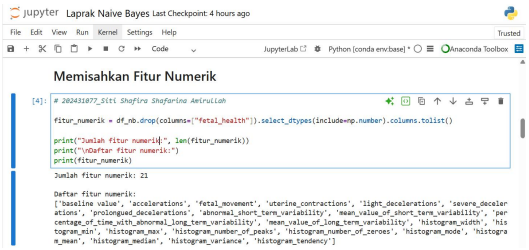
Kode mengimpor library yang dibutuhkan untuk mengolah data, membuat visualisasi, membagi data latih dan data uji, serta membangun model klasifikasi Gaussian Naive Bayes. Output menunjukkan seluruh library berhasil diimpor tanpa error.



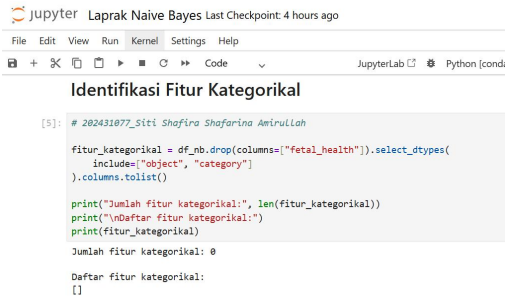
Kode membaca file fetal_health.csv menggunakan pandas dan menyimpannya ke variabel df_nb. Dataset memiliki 2.126 baris dan 22 kolom, sedangkan head() digunakan untuk melihat lima data pertama.



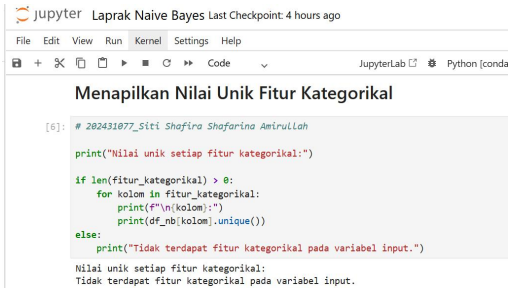
Kode digunakan untuk mengetahui struktur dan karakteristik dataset. Hasilnya membantu melihat tipe data, kelengkapan data, serta gambaran statistik dari setiap fitur numerik.



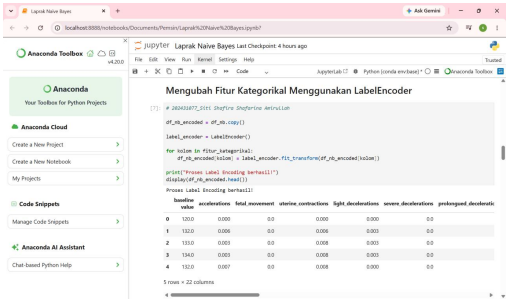
Kode memisahkan kolom target fetal_health, kemudian memilih seluruh kolom yang bertipe numerik. Hasilnya terdapat 21 fitur numerik yang akan digunakan untuk memprediksi kategori kesehatan janin.



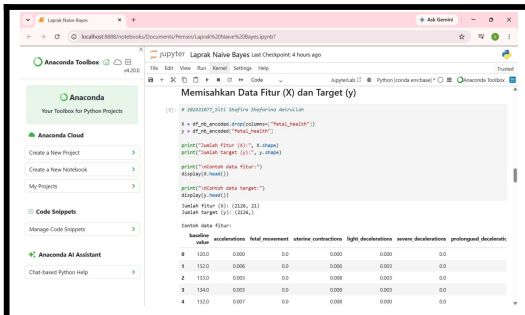
Kode memeriksa apakah terdapat fitur bertipe kategorikal selain kolom target. Hasilnya menunjukkan tidak ada fitur kategorikal karena seluruh 21 fitur prediktor sudah berbentuk numerik, sehingga tidak memerlukan proses konversi menggunakan LabelEncoder.



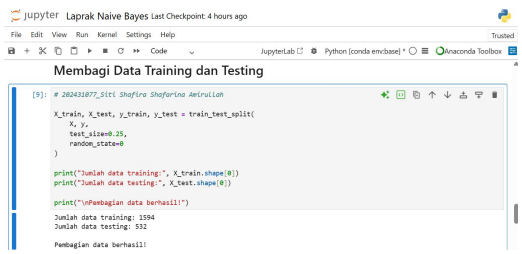
Kode memeriksa nilai unik pada setiap fitur kategorikal. Karena tidak terdapat fitur kategorikal pada variabel input, program menampilkan pesan bahwa tidak ada nilai yang perlu diperiksa.



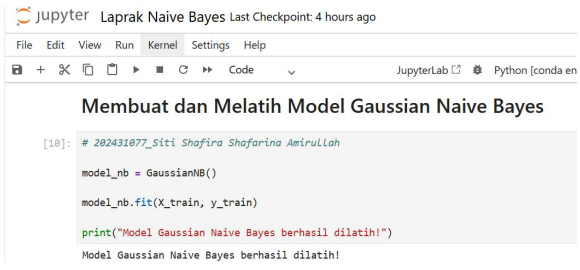
Kode menyalin dataset asli dan menyiapkan proses Label Encoding untuk mengubah data kategorikal menjadi angka. Karena tidak terdapat fitur kategorikal, tidak ada kolom yang diubah dan data tetap sama seperti dataset awal.



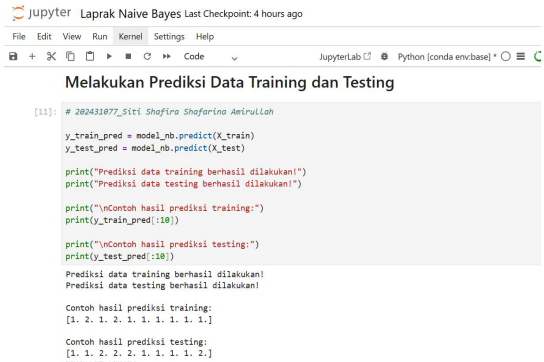
Kode memisahkan dataset menjadi variabel fitur (X) yang berisi 21 kolom prediktor dan variabel target (y) yang berisi kolom fetal_health. Pemisahan ini dilakukan agar model Naïve Bayes dapat mempelajari hubungan antara fitur pemeriksaan dan kategori kesehatan janin.



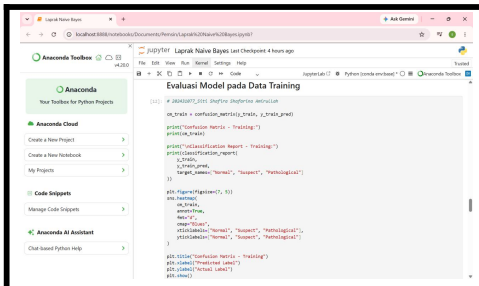
Kode membagi dataset menjadi 75% data training dan 25% data testing. Data training digunakan untuk melatih model, sedangkan data testing digunakan untuk menguji kemampuan model dalam memprediksi kategori kesehatan janin.

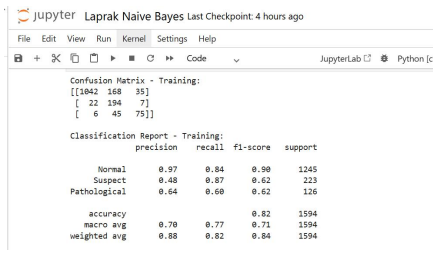


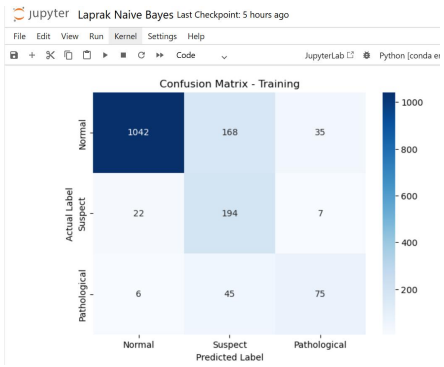
Kode membuat model Gaussian Naive Bayes dan melatihnya menggunakan data training. Setelah proses pelatihan berhasil, model siap digunakan untuk memprediksi kategori kesehatan janin berdasarkan data testing.



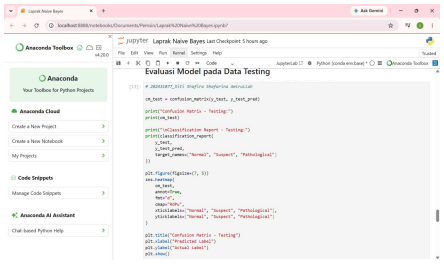
Kode menggunakan model Gaussian Naive Bayes yang sudah dilatih untuk memprediksi kategori kesehatan janin pada data training dan testing. Hasil prediksi berupa angka kategori fetal_health, yaitu 1 (Normal), 2 (Suspect), dan 3 (Pathological).

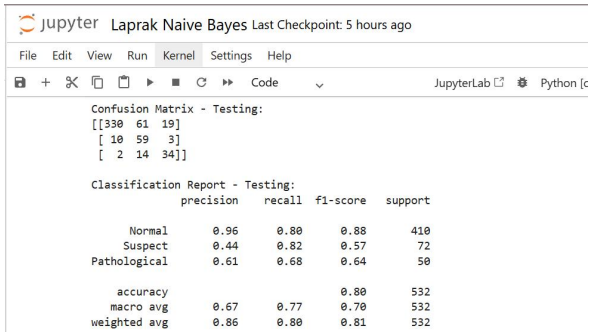


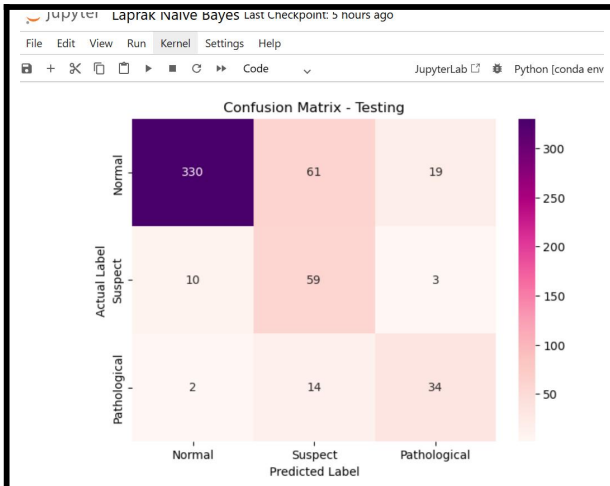




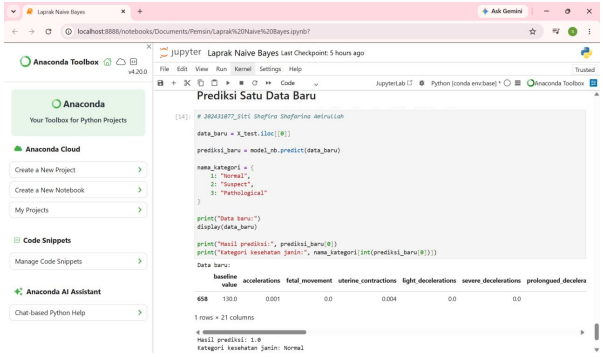
Kode mengevaluasi hasil prediksi model pada data training dengan membandingkan kategori sebenarnya dan hasil prediksi. Confusion Matrix menunjukkan jumlah prediksi benar dan salah, sedangkan Classification Report digunakan untuk melihat performa model pada setiap kategori kesehatan janin.







Kode mengevaluasi kemampuan model Gaussian Naive Bayes dalam memprediksi data testing yang belum digunakan saat pelatihan. Confusion Matrix dan Classification Report digunakan untuk mengetahui ketepatan prediksi model pada setiap kategori kesehatan janin.



Kode mengambil satu sampel data dari data testing, kemudian memprediksi kategori kesehatan janin menggunakan model Gaussian Naive Bayes. Hasil prediksi berupa angka yang diterjemahkan menjadi nama kategori agar lebih mudah dipahami.